最近大伙刷视频的时候，有没有发现评论区不太对劲？

大量的"海洋生物"涌了进来，最常见的是 DeepSeek 鲸鱼娘，其次还有 GPT、Claude、GLM、Qwen、Grok 等——各家 AI 的二创拟人角色。

这不是整活，这是 **AI 人格化的新浪潮**。

而我们组的 SenTrix-Home-Web-2.0，正好和这个方向有相似之处。这就是我本周的项目——SenTrixWhale。



PRE-RESEARCH PROPOSAL · V0.1 · 2026.11.02

SentrixWhale

给家庭记忆助手装上"人人可用"的对话入口

基于 sentrix-home-web-2.0（组内记忆助手工程）· 个人QQ交互套件（已验证原型）

AI 人格化角色火遍 B 站，却都聊完即忘，不能长久保存

DeepSeek鲸鱼娘、GPT白龙娘、Gemini哈基米娘、Claude学者娘，Grok哥特娘…AI 人格化角色已在 B 站各分区自成一景——但共同短板是没有长久的记忆机制：

01　聊完即忘——单次对话结束，上下文到上限就清零
02　沉淀不下来——没有可检索、可复查的长期记忆
03　更无法复现——AI 说「我记得」，你拿不出证据让它调出来给你看

我们手里正好有两块现成拼图

记忆内核
sentrix-home-web 2.0
VLM → 多通道索引 → 检索 → QA 评测

→ **完整记忆内核**
能沉淀 · 能检索 · 能评测

对话套件
QQ 交互套件（已验证）
护栏 · 日记 · 书房 · 识图
防幻觉

→ **全链跑通**
交互有温度 · 已有真机验证

拼起来 = SentrixWhale：**有记忆、能陪伴、可复现**的个人 AI——记忆有堤坝，交互有温度

02 · WHY QQ

对话入口，为什么选 QQ

从 B 站这股东风切入，落地选 QQ 做载体；微信虽最常用，但不得不舍弃

为什么不是微信

微信是时下最常用的通讯工具，人手一个，但腾讯对机器人管控严厉、个人号封号风险高——**不得不舍弃**

三种常见形态

B站视频搭子 — 切入点
风口来源 · 与产品形态不直接对接

QQ — 选用 →
与产品形态最对接 · 主做方向

桌宠 — 观望
未来可发展方向

01 **零门槛交互**：不用打开网页、不用学命令，发一句话、发一张照片，记忆就开始沉淀

02 **生态已验证可行**：QQ 机器人生态（NapCat 等开源协议端）存续 5 年+，稳定可用，是个人开发者验证与部署的更优选择

03 **补齐最后一层入口**：记忆助手从"评测工程"变成"人人可用的产品"，差的只是一层对话入口

选择 QQ：最低的用户成本，已验证的生态基座

个人账户 14 天未封禁 · 协议端可插拔 · 可切官方 API

03 · PROVEN CAPABILITIES

六项能力已全链跑通，不是纸面方案

全部来自线上真实运行记录，非演示、非纸面承诺

能力	说明	状态
费用护栏	双计数 + 日限额 + 日账单，可控可对账	**24 天 0 风险提示**
定量日记	按对话量自动沉淀小结，可翻 14 天内的指定日期	**每日运行**
书房	主人投喂长文，AI 主动阅读归档	**已实测**
图像识别	135/135 描述基本准确 · Qwen 89 分 · MiniCPM 82 分	**全量通过**
防幻觉	可追溯标准（找不到原句依据宁可不写）+ 温度分层	**已上线**
视频转文字	轻量版已跑通（2 个 B 站视频实测）· 正式管线阶段 2 接入	**已跑通**

来源：QQ 套件线上实测（10-20 ~ 11-12）· 总消耗 12.78 元 · 日均 0.53 元 · 峰值 1.51 元

草稿 · ARCHITECTURE

架构总览：从 QQ 到本地模型的四层链路

① QQ 接入层	NapCat 协议端 · OneBot11 / WebSocket 收发消息
② bridge（Node · 90）	收发消息 / 去重 / 时间解析 / 相册路由 / 存图归档 + 写 EXIF / 超时兜底
③ 记忆与存储	SHW 2.0（8191）多通道检索 · 事件 / 时间线；media/photos 地理目录
④ 模型层（本地）	Qwen3.5-Q4KM · llama.cpp（8100）· 本地推理，对话不出机器

bridge 是中间枢纽：一路检索回 SHW，一路落图到地理目录，结果再交本地模型组织成人话

草稿 · SAVE FLOW

存：一张张发进来，边聊边把回忆归好位

定位：SenTrixWhale 是依附 SHW2.0 的附属对话工程

大批量历史照片仍从网页端导入；QQ 里的鲸鱼助手只负责检索与聊天，一张张收下家庭日常。
你发来照片时，她像聊天一样接住，进入「聊天 + 回忆」的状态，而不是让你填表单。

1 你随手发来一张照片，她先温柔接住，不急着追问

2 缺时间或地点时，她轻声问一句：什么时候、在哪儿拍的？

3 解析出相册路径与时间，归档到地理目录，时间写进 EXIF

4 回你一句确认并复述出处，方便你核对，收好这张回忆

前提（实测）：原相机拍摄 + 勾原图，拍摄时间可自动识别；GPS 华为实测源头不写，不可得。
带时间 / 地点的图自动入册，缺什么补问什么；地点默认靠口述。**目录是真相，EXIF 是派生。**

草稿 · RECALL FLOW

取：问一句话，怎么把记忆说出来

1 用户问「2023 年 4 月」→ 解析出时间区间

2 SHW 检索：时间窗 + 语义匹配

3 取时间线事件摘要：「石家庄裕华公园吃草莓」

4 Qwen3.5 组织成一句人话 → 回「记得！咱们 2023 年 4 月在…」

关键取舍：向量检索只返回文件名和时间，说不了话；真正能「说事」的是时间线里的事件摘要。bridge 把事件摘要当**事实**喂给模型，而不是报「命中 N 条」让模型自己编。

草稿 · ALBUM TREE

相册怎么分：地理树分三层，区分到「能力边界」为止

分支	层级	做不做区
全球	洲 / 国 / 市（德国柏林、日本东京）	暂时不做
全国	省 / 市（陕西西安、福建厦门）	暂时不做
用户所在本地省	市 / 区（深圳南山、广州天河）	**做**

为什么外地不做区：这不是精度偏好，是能力边界。
深圳的「南山」「福田」天天在、张口就来；去趟西安不一定记得「碑林区」——做了也空着。
地名走内置地理库解析（2869 区县 + 46 国），与记忆内核用同一份行政边界，不会出现「她说的区和文件夹里的区对不上」。

草稿 · THREE RULES

三条铁律：守住边界，也把人稳稳接住

1 **词典只管「归位」，不管「能不能存」**

词典里没有的地名（如波尔图）照样建「全球/未归类/波尔图」，不拒收、不打发

2 **说得出区就记区，说不出就停在市，不逼问**

粒度跟用户实际掌握的信息走，问到答不上来就停下，不催

3 **时间解析不出来就不写，不猜「今天」**

猜错时间会把「没存到」变成「存错了地方」，宁可留空也不硬补

她不是冷冰冰的规则机器：不猜、不逼、不拒，背后是把家人的回忆稳稳接住的温度。

现在能演示什么：六项都有真机或用例佐证

能力	状态	佐证
QQ 问「2023 年 4 月」→ 答出具体事件	**真机**	「石家庄裕华公园吃草莓」
问「上周拍了什么」→ 老实说没存	**真机**	检索为空，不编造
发图 → 追问相册日期 → 入库	**本地端到端**	落盘 + EXIF + scope
带 GPS + 时间的原片 → 全自动入册	**代码级验证**	自动识别相册 / 时间 / 坐标，一句话不问
时间解析 36 条用例	**用例全绿**	20230429 / 去年 / 5 个月前 / 2023 年 4 月
防幻觉	**已上线**	检索为空时明确禁止编造

注记：现有手机照片均无 GPS（传递中丢失或未开定位），待真机补测

05 · VERIFIABLE MEMORY

每段记忆，都是一条可验证的依据

写入时自动留证，你随口一问，它答完必须把原始证据摆出来

1 · 写入时

自动生成记忆卡

每条记忆写入时，自动绑定：内容 + 出处（原照片/原对话）+ 一个验证问题

2 · 验证时

你随口考它

"你还记得上周我们说的那个 XX 吗？"——考的是内容，不是让它帮你找东西

3 · 判定时

必须出示证据

答完自动附上原照片 / 原句——对得上 = 真记得，对不上 = 编的

证据在你自己的库里——AI 说了不算，证据说了算

06 · MOAT & PROOF

我们的优势：数据在用户手里，入口在日常通讯里

三个优势叠在一起——单点能抄，组合抄不走

01 数据护城河

DATA MOAT

记忆库是用户自己的，越用越厚；迁走 = 记忆全丢——粘性来自自己的数据

02 入口护城河

ENTRY MOAT

嵌在日常通讯里，聊天 = 高频记忆写入；Replika / ChatGPT 是独立 app，我们是每天必开的 QQ

03 工程组合壁垒

ENGINEERING MOAT

护栏 + 质检 + 可考核 + 档案抗衰全链；单点功能可抄，组合与打磨难抄

现场活例 · demo 标准环节

现场写入（当场发照片 / 说事件）→ 当场考（"刚才照片里谁穿了红衣服"）→ **翻旧账**（三个月前的组内历史相册，现场提问——检索命中 + 原照片出示）

别人抄了怎么办：数据在用户侧抄不走，组合能力抄了也得磨半年——继续跑就是优势

从 DS 云端到端侧本地：同一入口，可切换底座

现在用 DS 最快出活；后面本地 GPU 准备好了，直接切端侧，不依赖任何外部服务

对比项	DS Flash（现状原型）	Qwen3.5-Q4KM（端侧目标）
成本	约 0.53 元/天 · 缓存命中 0.02 元/M	**0 元 · 本地 GPU 推理，KV cache 免费**
隐私	对话出机 · 经 DS API 中转	**对话不出机器 · 数据+模型全本地**
产品化	依赖 DS Key · 需单位/个人账号	**完全自包含 · 本地模型+QQ 零外部依赖**

思路：先用 DS 把产品跑通，后面切本地模型，入口和记忆层不用动

草稿 · DECISIONS

关键技术决策：六个取舍，背后都有理由

决策	理由
用 QQ 不用微信	微信个人号封号风险高；QQ 协议端生态存续更久
底座选本地模型	对话不出机器，模型留在本机，零外部依赖
喂模型用事件摘要	文件名说不了话，摘要才能支撑「记得」
目录是真相，EXIF 是派生	QQ 传图元数据不可靠，文件名和目录才是检索依据
scope_id 用完整路径	搜「深圳」能前缀命中它下面的所有区
不伪造 GPS	假坐标会让「可验证」变成「不可信」

草稿 · GAPS

还没做的：缺口如实交底

缺口	现状 / 影响
「收回刚才那张」暂存区	三轮拒收后图就丢了，「后话」落空；需要一个 10 分钟暂存区
检索按相册过滤	周五 / 下周排期；目前检索不按相册收敛
主题册（猫、生日）	目前只有地理树，没有主题维度
新存图的人脸聚类	入库时不触发聚类，问「照片里有谁」还答不上



END · NEXT STEP

记忆有堤坝，交互有温度

SentrixWhale · 给家庭记忆助手装上"人人可用"的对话入口

今天对齐 · 明天开工 · 本周末组会可以初步成果展示框架

预研提案 · v0.2 · 2026.11